

{% include header.html %}

---

{% include ai-share.html %}

---

{% include price.html %}

---

# LLM

---

大語言模型 (Large Language Model)

- [AlpacaEval Leaderboard](#)
  - [Open LLM Leaderboard](#)
  - [Big Code Models Leaderboard](#)
- 

- [Awesome-Chinese-LLM](#)
- 

- [大模型所需GPU 記憶體筆記](#)
  - [不同參數規模大語言模型在不同微調方法下所需的顯存總結](#)
- 

- [人工智慧大語言模型微調技術：SFT 監督微調、LoRA 微調方法、P-tuning v2 微調方法、Freeze 監督微調方法](#)
  - [LoRA、完全微調到底有何不同？MIT 21頁論文講懂了](#)
  - [大模型微調 \( Fine-tuning \) 全解，需要了解的都在這裡](#)
  - [初學者必看大模型微調指南：Unsloth官方微調技巧大公開！](#)
  - [零代碼！一站式完整資料集準備到模型微調全流程！](#)
  - [把你的DeePseek-R1 微調為某個領域的專家？](#)
  - [使用 NVIDIA NeMo 框架進行 LLM 模型剪枝和知識蒸餾](#)
  - [LLaMA Factory](#)： <https://huggingface.co/spaces/hiyouga/LLaMA-Board>
    - [官方 README\\_zh.md](#)
    - [2024-09-13：解析Llama-Factory：從微調到推理的架構](#)
    - [單卡3 小時訓練專屬大模型Agent：基於LLaMA Factory 實戰](#)
  - [torch tune](#)： <https://github.com/pytorch/torch tune>
    - <https://pytorch.dev.org/torch tune/stable/index.html>
    - [使用知識蒸餾將Llama3.1 8B 蒸餾到Llama3.2 1B](#)
- 

- [微調特定領域的大模型，資料集究竟要怎麼搞？](#)
  - [LLaMA Factory 微調教學：如何建立高品質資料集](#)
  - [大模型微調資料集生產工具 Easy Dataset](#)
  - [開源DeepWiki版支援根據現有檔案產生微調資料集](#)
  - [零一萬物發布COIG-CQIA：高品質且符合人類互動行為的中文指令微調數據](#)
-

- [AI Search Has A Citation Problem](#)
- [AI Agents vs. Agentic AI: A Conceptual Taxonomy, Applications and Challenges](#)
- [OWASP Agentic AI – Threats and Mitigations](#)

| Tool 名稱  | 功能<br>範疇                                    | 集成能力                                                          | 適用場景                               | 建議選擇                                               | 知識庫技術                                                                                          |
|----------|---------------------------------------------|---------------------------------------------------------------|------------------------------------|----------------------------------------------------|------------------------------------------------------------------------------------------------|
| Flowise  | 簡單<br>可視<br>化流<br>程建<br>構                   | 支持<br>LangChain 和<br>GPT，多平台部<br>署                            | 快速構建簡單<br>LLM 流程應<br>用             | 適合需要快速<br>構建和部署<br>LLM 應用的用<br>戶                   |                                                                                                |
| Langflow | 多智<br>能體<br>與<br>RAG<br>應用<br>構建            | 外部工具、API<br>與資料庫集成                                            | 複雜任務鏈與<br>多智能體應用<br>開發             | 適合構建複雜<br>任務鏈的技術<br>型開發者                           |                                                                                                |
| Dify     | 全面<br>應用<br>開發<br>與管<br>理                   | 多模型支持，<br>全面工作流與<br>模型管理                                      | 全生命周期管<br>理與複雜應用<br>開發             | 適合需要全面<br>管理 LLM 應用的開發者或企<br>業                     | 基於 Pinecone 的向量數據<br>庫、Notion API 同步（增量更<br>新）、支持 Rerank 模型<br>（bge-reranker-base）、提供<br>行業模板庫 |
| n8n      | 通用<br>自動<br>化與<br>流程<br>編排<br>平台            | 支持超過 350<br>種服務與 API<br>集成，可視化<br>流程編輯                        | 應用整合、自<br>動化工作流程<br>構建、自動回<br>應觸發器 | 適合需要自動<br>處理非 AI 任務<br>或整合各類<br>SaaS 工具的用<br>戶與開發者 | 可與向量資料庫結合使用，但<br>非內建                                                                           |
| RAGFlow  | 模組<br>化<br>RAG<br>管線<br>與知<br>識應<br>用框<br>架 | 支持<br>LangChain、<br>Chroma、<br>FAISS 等，可用<br>於構建完整<br>RAG 工作流 | 知識問答、文<br>件檢索、RAG<br>多階段優化         | 適合需要建構<br>可定製、模組<br>化 RAG 系統的<br>開發者               | 支持多向量資料庫<br>（Chroma、FAISS）、可結合<br>自定義資料源與檢索策略                                                  |
| New API  | 模型<br>接口<br>統一<br>與分<br>發                   | OpenAI 格式統<br>一，支持多支<br>付協議與分發<br>管理                          | 多模型接口管<br>理與分發                     | 適合需要統一<br>管理多種 AI 模<br>型接口的用戶                      |                                                                                                |

| Tool 名稱           | 功能<br>範疇      | 集成能力                                | 適用場景                        | 建議選擇                           | 知識庫技術                                                                         |
|-------------------|---------------|-------------------------------------|-----------------------------|--------------------------------|-------------------------------------------------------------------------------|
| XORBITS Inference | 分散式推理與部署      | 與 Hugging Face 等模型相容，支援雲端及本地等多種部署環境 | 大規模模型推理與雲端部署，需快速搭建可擴展的推理服務時 | 適合需要高效擴展能力、進行大規模模型推理的團隊或企業     |                                                                               |
| Ollama            | 本地模型推理與管理     | 提供命令列介面，支援多種 Llama 模型於本地運行          | 在有隱私或離線需求的場景下進行本地推理         | 適合想在本地快速配置 Llama 系列模型的個人或中小型團隊 |                                                                               |
| FastGPT           | 知識庫問答系統與工作流編排 | 提供開箱即用的數據處理、模型調用，支持可視化工作流編排         | 快速構建智能問答系統與複雜問答場景           | 適合需要快速部署知識庫問答系統的用戶             | 混合索引 ( Elasticsearch + FAISS )、支援 PDF 表格解析 ( PyMuPDF 集成 )、BM25 權重可調、需人工標註種子數據 |
| Coze              | AI 智能體開發平台    | 整合插件、長短期記憶、工作流、卡片等功能，支持多平台發布        | 低門檻快速搭建個性化或具備商業價值的智能體       | 適合無需編程即可創建智能體的用戶               | 自研分佈式索引、電商數據結構                                                                |

工具

- MCP
    - 2025-04-15：[automcp](#)：將任何代理、工具或編排器秒設定 MCP 伺服器
    - 2025-04-10：[line-bot-mcp-server](#)
    - 2025-04-05：[GitMCP](#)：GitMCP 太神了！一行URL 讓AI 秒懂你的GitHub 項目
    - 2025-03-14：[playwright-mcp](#)：MCP-Playwright：AI自動化神器
  - Browser-use
    - 2025-06-04：[workflow-use](#)：基於AI 的瀏覽器自動化工具：一次錄製，永久重複使用
    - 2025-04-16：[browser-use/web-ui](#)；如何使用
    - 2025-03-28：[browser-use-webui](#)
    - 2025-02-16：[browser use webui](#)部署（實現瀏覽器自動化）
    - 2025-01-23：[Browser Use](#) – 讓AI 像人類一樣使用瀏覽器
- 
- 2025-07-30：[langextract](#)；隆重推出 LangExtract：由 Gemini 驅動的資訊擷取庫
  - 2025-07-26：[presenton](#)；一款可本地部署的開源AI PPT項目，一鍵生成精美PPT
  - 2025-07-03：[MultiAgentPPT](#)；A2A+ADK+MCP多智能體並發系統產生(可線上編輯) 的PPT ( 含原始碼 )
  - 2025-06-28：[docext](#)：基於Qwen2.5VL的文檔解析工具

- 2025-06-10 : [Agentic-Doc](#) ; [LandingAI](#)開源神器，這個Python庫讓百頁文檔秒變結構化資料！
- 2025-06-06 : [daily-arXiv-ai-enhanced](#) : 每日自動爬取arXiv論文並以LLM產生中文摘要
- 2025-05-22 : [AingDesk](#) ; [AingDesk](#) : 零門檻本地 AI 部署
- 2025-05-20 : [news-agents](#)
- 2025-05-16 : [Follow](#) ; 連續登頂GitHub 的資訊聚合神器 : [Follow](#)，讓你不再錯過任何重要資訊！
- 2025-05-11 : [SurfSense](#) : GitHub 開源專案 打通Notion、GitHub、搜尋引擎的AI超腦，如何使用
- 2025-04-28 : [PaperCoder](#) ; [Paper2Code: Automating Code Generation from Scientific Papers in Machine Learning](#) ; [PaperCoder](#) : 利用大型語言模型自動產生機器學習論文程式碼的框架
- 2025-04-16 : [OneFileLLM](#) : 這個開源神器終結了AI資料整合的惡夢！一鍵聚合網頁、程式碼、論文到剪貼簿！
- 2025-04-16 : [ScrapeGraphAI](#) : [ScrapeGraphAI](#) - 自然語言驅動的智慧爬蟲革命！
- 2025-04-15 : [stagehand](#) : [Stagehand](#) : AI驅動的下一代瀏覽器自動化框架
- 2025-04-11 : [nanobrowser](#) : AI 驅動的瀏覽器自動化神器
- 2025-04-10 : [DevDocs](#) : 開發者的文檔收割機來了！這個開源工具讓你一小時幹完一週的活！
- 2025-04-06 : [sqlchat](#) : 這款開源神器讓資料庫管理像聊天一樣簡單！
- 2025-03-26 : [pdf-craft](#) : PDF秒轉Markdown/EPUB
- 2025-03-25 : [OCRmyPDF](#) ; [OCRmyPDF](#) 能力分析
- 2025-03-12 : [AingDesk](#) ; 零門檻本地AI 部署，[DeepSeek](#)、[Llama](#) 一鍵直達！
- 2025-03-08 : [composio](#) : AI助理效率神器！[Composio](#)幫你輕鬆整合200+工具
- 2025-02-25 : [PySpur](#) : 拖曳式開發AI工作流程！這款開源神器，讓LangChain也黯然失色！
- 2025-01-13 : [DocAligner](#) : 拍照文件復原：校正扭曲、光照陰暗、版面定位
- 2025-01-13 : [PPTAgent](#) ; 中科院開源AI工具，自動將文件轉化為高品質PPT
- 2025-01-07 : [activepieces](#) : 一個開源的AI自動化工作流程工具
- 2024-12-15 : [markitdown](#)

## AI Agent 開源框架

- 從AI Agent到Agent工作流程，一文詳細了解代理程式工作流程
- 萬字長文，帶你綜觀大模型Agent，涉及研究痛點、應用場景、發展方向
- 什麼是「Agentic 工作流程」？
- 什麼是Agentic AI？什麼是Agentic Workflow？與AI Agent有什麼區別和關聯？
- [FinRobot](#) ; [DeepWiki](#) ; 可支援 Gemini-2.5-Pro-preview-05-06，基於 AutoGen
- [Jupyter-AI](#) ; 可支援 Gemini-2.5-Pro-preview-05-06

- 
- 2025-07-03 : [multi-modal-researcher](#)
  - 2025-06-25 : [Gemini CLI](#) : [Gemini CLI](#) : 你的開源 AI 代理
  - 2025-06-06 : [PandaWiki](#) ; 新一代AI 大模型驅動的開源知識庫建立系統
  - 2025-06-03 : [Gemini Fullstack LangGraph](#) ; DEMO ; 以為Google只是簡單放個Demo，哪想到是「開源版」Perplexity！
  - 2025-06-03 : [Perplexica](#) ; [Perplexity AI](#)，開源替代品
  - 2025-06-02 : [Paper2Poster](#) : 自動為論文產生海報
  - 2025-06-01 : [Agent Zero](#) ; 官網 ; 這個自動AI代理可以做任何事！（產生APP、程式碼、RAG 等）
  - 2025-05-30 : [WebDancer @ Alibaba](#) ; [DeepWiki](#)
  - 2025-05-28 : [Lemon AI](#) ; 全球首款全端開源通用AI Agent，讓人可以單機部署超級智慧體
  - 2025-05-25 : [OpenHands](#) ; DEMO
  - 2025-05-18 : [Agent-Squad](#) ; 輕量級開源AI多智能體框架！智慧路由+上下文管理，前後端介面支援！

- 2025-05-10 : [FlowGram](#) : 字節跳動把Coze 核心開源了！視覺化工作流程引擎FlowGram 上線；如何使用
- 2025-05-10 : [DeerFlow](#) : 字節跳動DeerFlow深度解析；如何使用
- 2025-05-09 : [OpenDeepWiki](#) : 開源的DeekWiki加入MCP，輕鬆讓AI掌握開源專案使用文件！；如何使用
- 2025-05-07 : [AI Manus](#)
- 2025-04-24 : [suna](#) : 3週時間，就打造出Manus開源平替！貢獻原始碼，免費用
- 2025-04-22 : [釦子空間 \(Coze Space\)](#) : 字節版Manus 釦子空間來了！實測效果絕佳，但還有3 個問題
- 2025-04-03 : [AutoAgent](#) : 一句話全自動創建AI智能體，港大AutoAgent打造開源最強Deep Research
- 2025-04-03 : [Agent Development Kit \(ADK\)](#) : 谷歌發表「智能體開發工具包」ADK，來嚐個鮮
- 2025-04-03 : [Deepsite](#) ; DeepSite基於DeepSeek的網頁開發智能體，效果非常不錯
- 2025-03-30 : [DeepGemini](#) : AI界的'搭積木'神器，10分鐘打造你的專屬智慧團隊！
- 2025-03-24 : [AgenticSeek](#) : 又一個“Manus”開源，完全本地化替代品AgenticSeek
- 2025-03-11 : [autoMate](#) : autoMate:基於OmniParser 所建構的革命性AI自動化助手
- 2025-03-10 : [OpenManus](#) : 一文讀懂：OpenManus
- 2025-02-28 : [MoneyPrinterTurbo](#) ; AI自動生成高清短視頻
- 2024-02-01 : [MobileAgent](#) : 一句指示幫你操作手機，最新多模態手機助理Mobile-Agent來了！
- 2025-01-03 : [smolagents](#) : 新年禮物，Huggingface捲了一個Agent專案開源
- 2024-09-23 : [STORM](#) ; STORM：一个基于LLM的知识整理系统
- 2024-10-26 : [OmniParser](#) ; 控制電腦手機的智慧體人人都能造，微軟開源OmniParser

## 世界模型

- 2025-09-25 : [Code World Model](#) : 程式碼生成要變天了？被質疑架空後，Yann LeCun攜320億參數開源世界模型“殺回來了”

## 混合專家(Mixture of Experts, MoE)模型

- 2024-12-13 : [DeepSeek-VL2](#) : DeepSeek-VL2開源，VLM邁入MoE時代，DeepSeek-VL2 先進視覺語言模型，在多模態理解方面取得了顯著進展
- [騰訊混元](#) : 騰訊混元又來開源，一出手就是最大MoE大模型
  - 2024-11-06 : [DEMO](#)
  - 2024-11-06 : [MODEL](#)

## 小型語言模型

- 2025-01-07 : [Smolagents](#) : Hugging Face開源全新AI智能體框架支援工具呼叫與程式碼執行！
- 2024-12-13 : [Phi-4](#) : 以小博大，微軟Phi-4正式發表~
- 2024-11-18 : [MobileLLM-1.5B](#) : Meta MobileLLM：深度架構與最佳化技術打造的行動裝置超強語言模型
- 2024-11-04 : [SmolLM2](#) : <https://github.com/hiyouga/LLaMA-Factory>
  - [Hugging Face](#)公布手機執行的小型語言模型SmolLM2
- 2024-09-25 : [Llama 3.2 90b, 11b, 3b, 1b: Revolutionizing edge AI and vision with open, customizable models](#)

## 推理模型

- 2025-08-05 : [gpt-oss](#) ; 隆重介紹 gpt-oss ; OpenAI重新開源！深夜連發兩個推理模型，o4-mini水平

- 2025-07-29 : [Llama Nemotron Super v1.5](#) ; 英偉達全新開源模型：三倍吞吐、單卡可跑，還拿下推理 SOTA
- 2025-07-27 : [OpenReasoning-Nemotron](#) ; 英偉達突然開源「數學核武」！ 1.5B 參數秒殺 o3 , [OpenReasoning-Nemotron](#) 真有這麼猛？
- 2025-05-06 : [Llama-Nemotron](#) ; [DeepWiki](#) ; 英偉達發布Llama-Nemotron系列大模型，實現高效推理
- 2025-04-16 : [Video-R1: Reinforcing Video Reasoning in MLLMs](#) ; [Github](#) ; 影片推理R1時刻，7B模型反超GPT-4o，港中文清華推出首款Video-R1

## 大型語言模型

- 2025-08-05 : [Claude Opus 4.1](#)
- 2024-11-23 : [Ai2 Tulu 3](#) : 這才是真·開源模型！公開「後訓練」一切，性能超越Llama 3.1 Instruct
  - DEMO : <https://playground.allenai.org/>
  - MODEL : <https://huggingface.co/allenai>
- 2024-11-9 : [Ai2 OpenScholar](#) : <https://openscholar.allenai.ai/>
- 2024-09-25 : [Llama 3.2 90b, 11b, 3b, 1b: Revolutionizing edge AI and vision with open, customizable models](#)

## Embedding & Reranker

- 2025-07-14 : [gemini-embedding-001](#)
- 2025-06-05 : [Qwen3 Embedding](#) : 新一代文本表徵與排序模型
  - 2025-06-03 : [Qwen3-Embedding](#)
  - 2025-06-03 : [Qwen3-Reranker](#)

## 語音到語音大模型及工具套件

- [ten-agent](#)
  - 又一款王炸級的開源端對端語音模型
  - [TEN Framework](#) 入坑記
  - 使用 [TEN Agent](#) 搭建 Conversation AI Agent
- [pipecat](#) : OpenAI工程師親自修訂：用ChatGPT即時語音API建立應用
- 2025-07-21 : [Audio Flamingo 3 @ NVIDIA](#) ; [NVIDIA](#) 開源多模態音訊模型Audio Flamingo 3
- 2025-05-08 : [Voila](#) ; 新型開源端對端AI 語音模型！ [Voila](#) : 195ms 超低延遲引領全雙工對話！
- [HuggingFace Speech-to-Speech](#)

## 視覺大語言模型 (Vision-Language model)

- 2025-05-20 : [Seed1.5-VL](#) ; [Seed1.5-VL](#) : 具有視覺增強多模態能力的高階語言模型；字節跳動發布 [Seed1.5-VL](#) 視覺-語言多模態大模型，實測效果非常不錯
- 2025-05-12 : [nanoVLM](#)

## 多模態大語言模型 (Multimodal)

- [InternVL](#)
  - (CVPR 2024 Oral) [InternVL3: Exploring Advanced Training and Test-Time Recipes for Open-Source Multimodal Models](#)
  - [DeepWiki](#) ; [InternVL3](#) : 刷新開源多模態大模型效能新紀錄
- 2025-05-24 : [Dolphin](#) : [DeepWiki](#) ; 開源多模態複雜文件解析模型！ [Dolphin](#)
- 2025-05-21 : [Gemma 3n](#) ; [Preview](#)

- 2025-03-18 : [Mistral Small 3.1](#) : [Mistral](#)開源多模態小模型3.1 : 128K上下文+超低延遲 , 效能碾壓GPT-4o Mini
- 2025-03-14 : [Vision-R1](#) : [Vision-R1](#) : 激發多模態大模型的推理能力
- 2025-02-28 : [HumanOmni](#)
  - [阿里通義開源業界首個第一視角大模型](#) , 超強的視訊理解效能 !
  - [首個專注於人類中心場景的多模態大模型](#) , 視覺與聽覺融合的突破 !
- [Phi](#)
  - [Phi-4-multimodal-instruct](#)
  - 2025-02-27
    - [微軟首個多模態Phi-4問世](#) , 56億參數秒殺GPT-4o ! LoRA華人大佬帶隊
    - [微軟發表Phi-4-Mini系列模型](#) : 小身材 , 大智慧 - 語言與多模態AI的新突破
  - 2024-09-12 : [微軟AI發布Phi 3.5 mini](#) 、[MoE](#) 和[Vision](#)
- [MiniCPM](#)
  - 2025-01-16 : [MiniCPM-o 2.6](#) : 流式全模態 , 端到端 , 多模態端側大模型來了 ! ; [文件](#)
  - 2024-09-11 : [升級Ollama ! MiniCPM-V2\\_6影像辨識模型上線](#)
  - 2024-09-06 : [MiniCPM 3.0 開源 ! 4B參數超GPT3.5性能](#) , 無限長文本 , 超強RAG三件套 ! 模型推理、微調實戰來啦 ! : <https://github.com/OpenBMB/MiniCPM>
  - 2024-09-05 : [零碼基礎都敢去魔改MiniCPM-V了 ? 是我飄了 , 也是Cursor 太強了](#) : <https://github.com/OpenBMB/MiniCPM-V/>